

Nama : Zsa Zsa Aulia Az Zahrah

Nim : 09021382328136

## REVIEW PAPER

### 1. Jurnal 1

<b>Judul</b>	Machine learning for combinatorial optimization: A methodological tour d'horizon
<b>Penulis</b>	Yoshua Bengio, Andrea Lodi, Antoine Prouvost
<b>Tahun</b>	2021
<b>Permasalahan</b>	Paper ini membahas bagaimana machine learning dapat digunakan untuk meningkatkan algoritma combinatorial optimization (CO). Masalah utamanya: CO (seperti MILP, TSP, dsb.) sering bergantung pada heuristic buatan manusia, yang tidak selalu optimal atau generalizable. ML digunakan untuk: <ul style="list-style-type: none"><li>- mempercepat perhitungan,</li><li>- membuat keputusan algoritmik (branching, cut selection),</li><li>- dan mempelajari pola dari kumpulan instance CO.</li></ul>
<b>Metode yang Digunakan</b>	Paper ini berupa survey, jadi tidak hanya satu metode: <ul style="list-style-type: none"><li>- <i>Supervised learning</i> untuk imitasi dari ahli (expert imitation).</li><li>- <i>Reinforcement learning</i> untuk belajar kebijakan optimasi secara langsung.</li><li>- <i>Neural networks</i> (MLP, RNN, Attention) untuk memodelkan struktur problem CO.</li><li>- Integrasi ML dalam <i>branch-and-bound</i> dan <i>branch-and-cut</i> di MILP solvers.</li></ul>
<b>Banyak Data</b>	Paper ini tidak melakukan eksperimen tunggal; karena ini review, dataset berasal dari berbagai penelitian sebelumnya. Contoh sumber data yang dibahas dalam literature: <ul style="list-style-type: none"><li>- Instances TSP</li><li>- MILP benchmarks</li></ul>

	<ul style="list-style-type: none"> <li>- Problem distributions industry</li> </ul> <p>semuanya tergantung studi sebelumnya, bukan paper ini sendiri.</p>
<b>Hasil/Akurasi</b>	<p>Karena ini survey paper, tidak ada hasil angka akurasi tunggal. Namun paper merangkum bahwa ML terbukti:</p> <ul style="list-style-type: none"> <li>- meningkatkan kualitas heuristik,</li> <li>- mempercepat proses branch-and-bound,</li> <li>- memberikan generalisasi yang baik pada data dengan distribusi mirip.</li> </ul>
<b>Kontribusi</b>	<p>Kontribusi utama:</p> <ul style="list-style-type: none"> <li>- Menyediakan kerangka metodologis untuk menggunakan ML dalam CO.</li> <li>- Menjelaskan dua pendekatan utama: imitasi ahli dan policy learning.</li> <li>- Menekankan pentingnya distribusi problem sebagai data (problem-as-data).</li> <li>- Menyediakan rangkuman literatur yang sistematis dan menjelaskan arah riset masa depan.</li> </ul>
<b>Kelebihan dan Kelemahan</b>	<p>Kelebihan:</p> <ul style="list-style-type: none"> <li>- Pembahasannya komprehensif dan terstruktur, sehingga memberikan gambaran menyeluruh tentang peran ML dalam combinatorial optimization.</li> <li>- Menyediakan klasifikasi metode yang jelas (supervised, reinforcement learning, dan integrasi ML dalam solver), sehingga memudahkan pembaca memahami pendekatan yang tersedia.</li> <li>- Mengumpulkan dan mensintesis literatur yang tersebar, sehingga menjadi rujukan kuat bagi peneliti yang ingin masuk ke bidang optimasi berbasis ML.</li> <li>- Menawarkan analisis kritis serta arah riset masa depan, yang membantu peneliti menilai tantangan dan peluang dalam pengembangan metode baru.</li> </ul> <p>Kelemahan:</p> <ul style="list-style-type: none"> <li>- Tidak ada eksperimen baru (karena memang review).</li> <li>- Beberapa penjelasan cukup teoretis sehingga berat bagi pemula.</li> </ul>

	<ul style="list-style-type: none"> <li>- Tidak menawarkan solusi praktis siap pakai; fokus pada konsep.</li> </ul>
--	--

## 2. Jurnal 2

<b>Judul</b>	An Effective Optimization Method for Machine Learning Based on ADAM
<b>Penulis</b>	Dokkyun Yi, Jaehyun Ahn, Sangmin Ji
<b>Tahun</b>	2020
<b>Permasalahan</b>	<p>Penelitian ini berangkat dari keterbatasan beberapa metode optimasi seperti Gradient Descent, Adam, dan AdaMax yang sering menghadapi hambatan ketika fungsi biaya bersifat non-konveks. Pada kondisi tersebut, optimizer dapat terjebak pada <i>local minimum</i> atau berhenti bergerak ketika gradien bernilai nol. Hal ini mengakibatkan proses pelatihan model tidak mencapai solusi yang optimal.</p> <p>Penelitian ini bertujuan mengembangkan metode optimasi yang lebih mampu menghindari <i>local minimum</i> dan mencapai performa yang lebih stabil.</p>
<b>Metode yang Digunakan</b>	<p>Penulis mengusulkan modifikasi terhadap algoritma Adam dengan menambahkan informasi fungsi biaya (<i>cost function</i>) ke dalam proses pembaruan parameter. Modifikasi ini tetap mempertahankan struktur Adam, namun menambahkan komponen tambahan sehingga pembaruan parameter tetap berlangsung meskipun gradien mendekati nol.</p> <p>Metode tersebut kemudian dibandingkan dengan tiga optimizer lain, yaitu:</p> <ul style="list-style-type: none"> <li>- Gradient Descent</li> <li>- Adam</li> <li>- AdaMax</li> </ul> <p>Evaluasi dilakukan melalui pengujian pada berbagai fungsi non-konveks serta model jaringan saraf (CNN dan ResNet).</p>
<b>Banyak Data</b>	<p>Penelitian ini menggunakan beberapa jenis data:</p> <ul style="list-style-type: none"> <li>- MNIST (60.000 data latih, 10.000 data uji)</li> <li>- CIFAR-10 (50.000 data latih, 10.000 data uji)</li> <li>- Beberapa fungsi non-konveks, antara lain:</li> </ul>

	<ul style="list-style-type: none"> <li>• Beale Function</li> <li>• Styblinski–Tang Function</li> <li>• Saddle Point Function</li> <li>• Kasus segmentasi berbasis koordinat</li> </ul>
<b>Hasil/Akurasi</b>	<p>Hasil pengujian menunjukkan bahwa metode yang diusulkan memberikan performa lebih baik dibandingkan GD, Adam, dan AdaMax, terutama dalam:</p> <ul style="list-style-type: none"> <li>a. Fungsi Non-Konveks: Metode baru mampu mencapai <i>global minimum</i>, sementara optimizer lain cenderung berhenti pada <i>local minimum</i>.</li> <li>b. MNIST (CNN) <ul style="list-style-type: none"> <li>- Nilai <i>loss</i> lebih rendah.</li> <li>- Beberapa sampel diklasifikasikan dengan benar oleh metode baru, namun salah oleh Adam.</li> </ul> </li> <li>c. CIFAR-10 (ResNet-44) <ul style="list-style-type: none"> <li>- <i>Training loss</i> dan <i>validation loss</i> lebih rendah dibandingkan Adam.</li> <li>- Proses pelatihan lebih stabil.</li> </ul> </li> </ul> <p>Secara keseluruhan, metode baru menunjukkan kinerja yang lebih baik dalam menghindari <i>local minima</i> dan menghasilkan konvergensi yang lebih stabil.</p>
<b>Kontribusi</b>	<p>Penelitian ini memberikan kontribusi sebagai berikut:</p> <ul style="list-style-type: none"> <li>- Mengusulkan optimizer berbasis Adam yang lebih efektif dalam kondisi non-konveks.</li> <li>- Menyediakan pembuktian matematis terkait kestabilan dan konvergensi.</li> <li>- Menampilkan evaluasi eksperimen yang komprehensif pada berbagai jenis fungsi dan dataset.</li> <li>- Menunjukkan bahwa metode ini dapat meningkatkan performa model CNN dan ResNet.</li> </ul>
<b>Kelebihan dan Kelemahan</b>	<p>Kelebihan:</p> <ul style="list-style-type: none"> <li>- Memberikan pendekatan yang relatif sederhana namun efektif sebagai pengembangan Adam.</li> <li>- Mampu menghindari <i>local minimum</i> dan menjaga pembaruan parameter tetap aktif.</li> </ul>

	<ul style="list-style-type: none"><li>- Diuji pada berbagai skenario sehingga hasilnya lebih meyakinkan.</li><li>- Terbukti bekerja secara konsisten pada dataset besar seperti MNIST dan CIFAR-10.</li></ul> <p>Kelemahan:</p> <ul style="list-style-type: none"><li>- Belum diuji pada domain lain seperti NLP atau tugas time-series.</li><li>- Tidak dibandingkan dengan optimizer modern lain seperti AdamW, Ranger, atau Lookahead.</li><li>- Parameter tambahan (<math>\lambda</math>) memerlukan penyesuaian lebih lanjut agar optimal.</li><li>- Analisis terkait kompleksitas komputasi belum dibahas secara mendalam.</li></ul>
--	--